

1. Comparación de Modelos Supervisados

1.1. Descripción del problema

El objetivo de este taller es implementar un flujo de trabajo completo de aprendizaje supervisado para comparar el desempeño de tres clasificadores: **Random Forest**, **kNN** y **SVM**.

El análisis se realizó sobre dos conjuntos de datos clásicos: **Iris**, que contiene 150 muestras con 4 características numéricas y 3 clases balanceadas; y **Diabetes**, que incluye 768 muestras con 8 atributos clínicos y una variable binaria (0: No Diabetes, 1: Diabetes), la cual presenta desbalance entre clases.

La importancia de este problema radica en que permite observar cómo los modelos se comportan en escenarios distintos: uno balanceado y de baja dimensionalidad (Iris), y otro más complejo y desbalanceado (Diabetes). El resultado esperado es evidenciar diferencias en precisión, robustez y sensibilidad de cada algoritmo, así como la relevancia del preprocesamiento.

1.2. Método de solución

Para abordar el problema, se diseñó un flujo de trabajo supervisado utilizando la librería `scikit-learn` en Python. El procedimiento consistió en:

- División estratificada de los datos en entrenamiento (80 %) y prueba (20 %).
- Preprocesamiento con `StandardScaler` en los modelos sensibles a la escala (kNN y SVM).
- Entrenamiento de los modelos: Random Forest, kNN y SVM.
- Validación cruzada 5-fold para estimar desempeño promedio.
- Evaluación en el conjunto de prueba con métricas (*accuracy*, *precision*, *recall*, *f1-score*) y matrices de confusión.
- Comparación de resultados para determinar fortalezas y limitaciones de cada algoritmo.

Los datos empleados fueron:

- **Iris**: 150 instancias con 4 características; 3 clases balanceadas.

- **Diabetes** : 768 instancias con 8 características clínicas; variable de salida binaria desbalanceada.

El pseudocódigo general de este procedimiento se presenta en el Algoritmo 1.

Algorithm 1: Flujo de trabajo supervisado

Entrada: Dataset D , Modelos $M = \{\text{RF}, \text{kNN}, \text{SVM}\}$

Salida: Métricas y matrices de confusión

Dividir D en train y test (80/20, estratificado);

Para cada modelo $m \in M$ hacer::

 Preprocesar datos si es necesario (escalado);

 Entrenar m con los datos de entrenamiento;

 Validar desempeño con **cross-validation** (cv=5);

 Evaluar m con los datos de prueba;

 Calcular métricas (accuracy, precision, recall, f1);

 Generar matriz de confusión;

Comparar resultados y seleccionar el modelo más robusto;

1.3. Resultados

La ejecución del código se realizó en Python, utilizando los archivos `iris.csv` y `diabetes.csv` como conjuntos de datos de entrada. El flujo de trabajo descrito permitió entrenar y evaluar los tres modelos (**Random Forest**, **kNN**, **SVM**) bajo un esquema de división estratificada (80/20) y validación cruzada 5-fold.

Los principales resultados obtenidos se resumen en la Tabla 1, donde se reportan los valores promedio de *accuracy* para cada combinación de dataset y modelo.

Cuadro 1: Resultados de *accuracy* promedio por modelo y dataset.

Modelo	Iris (Accuracy)	Diabetes (Accuracy)
Random Forest	0.9667	0.7670
kNN	0.9733	0.7240
SVM	0.9667	0.7591

Además de las métricas globales, se generaron matrices de confusión que permiten analizar los errores de clasificación. A continuación, se presentan las gráficas correspondientes para cada modelo y dataset:




Figura 1: Matriz de confusión del modelo Random Forest en el dataset Iris.




Figura 2: Matriz de confusión del modelo kNN en el dataset Iris.




Figura 3: Matriz de confusión del modelo SVM en el dataset Iris.




Figura 4: Matriz de confusión del modelo Random Forest en el dataset Diabetes.




Figura 5: Matriz de confusión del modelo kNN en el dataset Diabetes.




Figura 6: Matriz de confusión del modelo SVM en el dataset Diabetes.

En términos generales, los modelos alcanzaron un desempeño cercano al 97% en el dataset Iris, mientras que en el dataset Diabetes el rendimiento fue menor (70–77%). Estos resultados muestran la diferencia en complejidad entre ambos problemas y reflejan la importancia del preprocesamiento y la elección de hiperparámetros en kNN y SVM.

1.4. Discusión

Los resultados muestran una clara diferencia entre los dos problemas analizados. En el dataset **Iris**, los tres modelos alcanzaron desempeños muy altos (accuracy cercano al 97 %), lo cual refleja la simplicidad del problema y el equilibrio en la distribución de clases.

En contraste, en el dataset **Diabetes**, los desempeños se ubicaron entre 70 % y 77 %, evidenciando la mayor dificultad asociada a datos desbalanceados y con mayor complejidad clínica. Esto resalta la importancia de aplicar técnicas de preprocesamiento y, en algunos casos, de considerar ajustes como balanceo de clases o selección de atributos relevantes.

Comparando los algoritmos, **Random Forest** mostró ser el más robusto al mantener un rendimiento competitivo en ambos datasets, mientras que kNN y SVM se vieron más afectados por el desbalance y la necesidad de un escalado adecuado.

En síntesis, se puede concluir que el tipo de dataset influye significativamente en el desempeño de los modelos, y que la elección del algoritmo debe considerar las características propias del problema a resolver.

1.5. Conclusiones

El presente trabajo permitió comparar el desempeño de tres algoritmos de clasificación supervisada (**Random Forest**, kNN y SVM) sobre dos conjuntos de datos con características contrastantes: uno balanceado y de baja dimensionalidad (*Iris*) y otro más complejo y desbalanceado (*Diabetes*).

De los resultados obtenidos se concluye que:

- Los modelos alcanzan altos niveles de *accuracy* en el dataset Iris (cerca al 97 %), lo que confirma que se trata de un problema sencillo y bien estructurado.
- En el dataset Diabetes, los valores de desempeño fueron menores (70–77 %), lo que refleja la dificultad de trabajar con datos clínicos más ruidosos y desbalanceados.
- **Random Forest** resultó ser el modelo más robusto, manteniendo un buen desempeño en ambos escenarios sin requerir un preprocesamiento intensivo.
- Algoritmos como kNN y SVM demostraron sensibilidad a la escala de las variables y al desbalance de clases, lo que resalta la importancia de aplicar técnicas de normalización y ajuste de hiperparámetros.

Cabe resaltar que, en el caso del dataset de Diabetes, métricas como el *recall* de la clase positiva (diabéticos) son especialmente relevantes, ya que en un contexto clínico un falso negativo puede tener consecuencias más graves que un falso positivo.

En términos generales, se evidencia que la elección del algoritmo depende en gran medida de las características del conjunto de datos. Asimismo, se destaca la relevancia de estrategias de preprocesamiento y validación cruzada para garantizar resultados más confiables y generalizables.